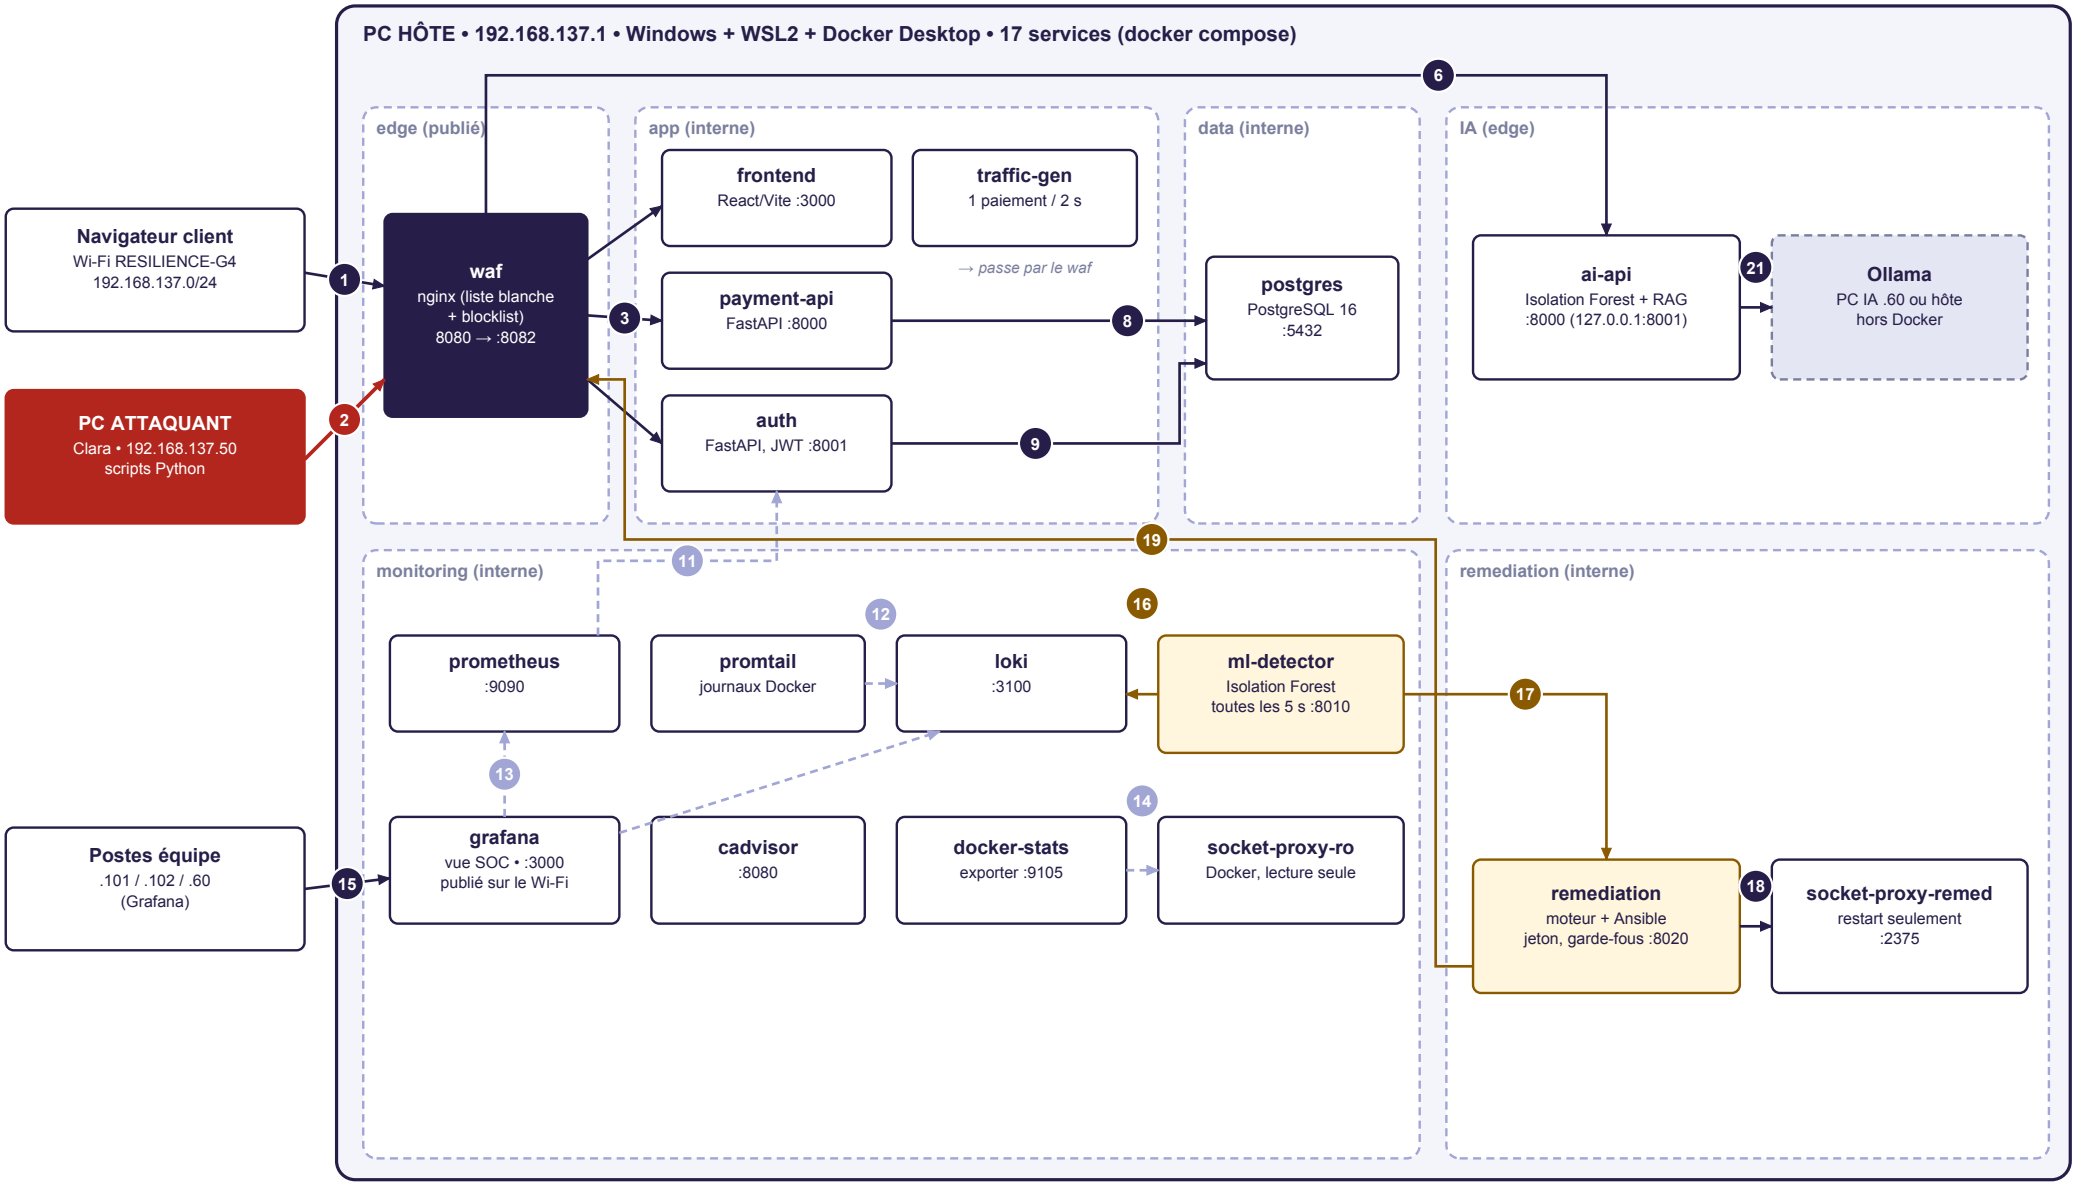
Architecture technique telle que construite

Ce document décrit ce qui tourne réellement, lu dans *docker-compose.yml* et le code (main, 21/10). La cible validée le 19/10 (v2.1) et les écarts sont en section 7.



Légende : **rouge** = attaque • **trait plein** = flux applicatif • **pointillés violets** = supervision • **orange** = remédiation (cadres orange = détection et remédiation) • **pastille n** = flux n° de la section 5

1 Machines et réseau du labo

Machine	Adresse IP	Rôle	Responsable
PC Hôte (Windows + WSL2 + Docker Desktop)	**192.168.137.1**	Point d'accès Wi-Fi **RESILIENCE-G4** + les 17 services Docker	Mélanie
PC Attaquant	**192.168.137.50**	Scripts Python de trafic et d'attaque (scripts/red_attack.py, normal_traffic.py)	Clara
PC IA	192.168.137.60	Ollama (modèle qwen2.5:1.5b) pour l'assistant RAG, hors Docker	Agathe
Postes équipe	192.168.137.101 / .102	Développement, accès à Grafana	Antoine, Timéo

IP fixes configurées à la main sur chaque PC (le hotspot Windows ne permet pas de réservation DHCP). Détails et commandes : *docs/plan-adressage.md*.

2 Ports publiés sur le PC Hôte

Port hôte	Service	Joignable depuis	Protection
8082	waf (point d'entrée unique)	Tout le Wi-Fi, y compris l'attaquant	Liste blanche de routes, liste de blocage, IP source non falsifiable
3000	grafana (supervision)	Tout le Wi-Fi (règle Docker Desktop du pare-feu)	Compte obligatoire, pas d'accès anonyme ni d'inscription
127.0.0.1:8001	ai-api	PC Hôte uniquement	Invisible depuis le Wi-Fi
—	postgres, payment-api, auth, prometheus, loki, remediation…	Jamais	Aucune directive ports: dans le compose

3 Réseaux Docker (5 zones)

Réseau	Sous-réseau	Interne	Membres
edge	10.77.10.0/24	non	waf, grafana, ai-api (seul réseau avec une sortie ; le waf y joint ai-api)
app	10.77.20.0/24	oui	waf, frontend, payment-api, auth, traffic-gen, prometheus, remediation
data	10.77.30.0/24	oui	postgres, payment-api, auth, remediation
monitoring	10.77.40.0/24	oui	prometheus, grafana, loki, promtail, cadvisor, docker-stats-exporter, socket-proxy-ro, ml-detector, remediation
remediation	10.77.50.0/24	oui	remediation, socket-proxy-remed (seul accès au redémarrage des conteneurs)

4 Les 17 services

Service	Techno (code)	Port	Réseaux	Rôle	État	Resp.
waf	nginx-unprivileged 1.28	8080	edge, app	Liste blanche : /, /api/{pay,health,transactions,waf/status}, /auth/*, /ai/* ; inclut la liste de blocage	**Fait**	Mélanie, Clara
frontend	React + Vite + Tailwind	3000	app	Paiement, compte, dashboard ; appelle /api, /auth, /ai via le waf ; contrôle de santé	**Fait**	Antoine
payment-api	FastAPI (backend/)	8000	app, data	Paiements, débit du solde si client authentifié, limitation de débit, /metrics	**Fait**	Antoine, Clara
auth	FastAPI (backend-auth/)	8001	app, data	Inscription, connexion (mots de passe scrypt, verrouillage après 5 échecs), JWT HS256, solde, dépôt	**Fait**	Antoine
postgres	PostgreSQL 16.10	5432	data	Comptes, transactions, journal d'audit ; rôle remediation_ro en lecture	**Fait**	Antoine, Mélanie
traffic-gen	Python	—	app	Trafic normal : 1 paiement toutes les 2 s via le waf	**Fait**	Mélanie
prometheus	Prometheus 3.5	9090	app, monitoring	Collecte des métriques toutes les 15 s	**Fait**	Mélanie
loki	Loki 3.5	3100	monitoring	Centralisation des journaux	**Fait**	Mélanie
promtail	Promtail 3.5	9080	monitoring	Lit les journaux des conteneurs et les envoie à Loki	**Fait**	Mélanie
grafana	Grafana 12.1	3000	edge, monitoring	Tableaux de bord, vue SOC	**Fait**	Mélanie, Clara
cadvisor	cAdvisor 0.52	8080	monitoring	Métriques des conteneurs	**Fait**	Mélanie
docker-stats-exporter	Python	9105	monitoring	Métriques par conteneur (Docker Desktop)	**Fait**	Mélanie
socket-proxy-ro	tecnativa 0.4.1	2375	monitoring	Accès Docker en lecture seule pour la supervision	**Fait**	Mélanie
ai-api	FastAPI, scikit-learn, LangChain, FAISS	8000	edge	Entraînement du modèle Isolation Forest + assistant RAG (procedures.pdf)	**Partiel**	Agathe
ml-detector	Python, scikit-learn (infra/ml-detector)	8010	monitoring	Toutes les 5 s : mesure 30 s de journaux (Loki), juge avec le modèle Isolation Forest, identifie la cause et alerte le moteur	**Fait**	Mélanie, Agathe
remediation	Python + Ansible (infra/remediation-engine)	8020	monitoring, remediation, app, data	Reçoit les alertes (jeton), choisit et lance le playbook, garde-fous (90 s, 3 actions / 10 min)	**Fait**	Mélanie
socket-proxy-remed	wollomatic 1.13	2375	remediation	N'autorise que la lecture et le redémarrage, depuis remediation seulement	**Fait**	Mélanie

5 Matrice des flux

Les numéros correspondent aux pastilles du schéma. Tout flux absent est interdit (pas de réseau commun ou réseau interne).

N°	Source	Destination	Port	Objet	État
1	Wi-Fi (navigateurs)	waf	8082	Accès à la plateforme : front, API, auth, assistant	**Fait**
2	**PC Attaquant .50**	waf	8082	**Attaque de démo** (flood sur /api/pay)	**Fait**
3	waf	frontend, payment-api, auth	3000, 8000, 8001	Routes autorisées uniquement (le reste répond 403)	**Fait**
4	frontend	waf	8080	Proxy du front : /api, /auth, /ai repassent par le waf	**Fait**
5	traffic-gen	waf	8080	Trafic normal, par le même chemin qu'un client	**Fait**
6	waf	ai-api	8000 (réseau edge)	Assistant et détection via /ai/*	**Fait**

N°	Source	Destination	Port	Objet	État
7	navigateur du PC Hôte	ai-api	127.0.0.1:8001	Accès direct local (non publié sur le Wi-Fi)	**Fait**
8	payment-api	postgres	5432	Transactions et débit du solde	**Fait**
9	auth	postgres	5432	Comptes, soldes, mots de passe hachés	**Fait**
10	payment-api	(aucun appel à auth)	—	Le jeton JWT est vérifié localement avec le secret partagé	**Fait**
11	prometheus	payment-api, auth, cadvisor, docker-stats, loki, promtail, ml-detector, remediation	/metrics	Collecte des métriques, dont le score ML et les actions de remédiation (ai-api n'est pas collecté)	**Partiel**
12	promtail	loki	3100	Envoi des journaux	**Fait**
13	grafana	prometheus, loki	9090, 3100	Tableaux de bord et vue SOC	**Fait**
14	promtail, cadvisor, docker-stats	socket-proxy-ro	2375	Lecture des conteneurs (GET seulement)	**Fait**
15	Postes équipe	grafana	3000	Supervision avec compte	**Fait**
16	ml-detector	loki, docker-stats-exporter	3100, 9105	Lecture des journaux du WAF et du trafic, état des conteneurs	**Fait**
17	ml-detector	remediation	8020	POST /alerts avec jeton : type (crash, dos, intrusion), service, score	**Fait**
18	remediation	socket-proxy-remed	2375	Redémarrage d'un conteneur en liste blanche	**Fait**
19	remediation	waf (volume + réseau app)	fichier, 8080	Règle de blocage écrite dans le volume waf-blocklist + paiement de test	**Fait**
20	remediation	postgres	5432	Contrôle d'intégrité, compte remediation_ro en lecture	**Fait**
21	ai-api	Ollama (PC IA ou hôte)	11434	Génération des réponses de l'assistant, seule sortie vers l'extérieur	**Fait**

À noter : Le plan d'adressage de Mélanie indique un flux payment-api → auth (vérification des jetons). Dans le code, payment-api vérifie le jeton lui-même avec le secret partagé et n'appelle jamais auth. À aligner dans *docs/plan-adressage.md*.

6 Sécurité en place (vérifiée dans le code)

Mesure	Où dans le code	État
Double WAF, niveau 1 (nginx) : point d'entrée unique, liste blanche de routes (/api/docs, /api/metrics, /api/waf/block → 403)	infra/placeholders/waf/default.conf	Fait
IP source non falsifiable : X-Forwarded-For forcé à l'IP vue par le WAF	default.conf (proxy_set_header … $remote_addr)	Fait
Liste de blocage dynamique (IP, User-Agent, limitation) écrite par Ansible	ansible/roles/waf_blocklist + volume waf-blocklist	Fait
Double WAF, niveau 2 (applicatif, dans payment-api) : limitation de débit, 40 requêtes / 2 s par client sur /pay	backend/app/waf.py	Fait
Routes /waf/block et /waf/unblock protégées par jeton (REMEDIATION_TOKEN)	backend/app/main.py	Fait
simulate_failure ignoré sauf si CHAOS_MODE_ENABLED=true côté serveur	backend/app/services.py	Fait
Authentification : mots de passe scrypt, verrouillage après 5 échecs par compte, jeton JWT HS256, débit du solde	backend-auth/app/main.py, backend/app/auth.py	Fait
Paiements anonymes encore acceptés (REQUIRE_AUTH=false par défaut)	docker-compose.yml	Partiel
Base non publiée, rôle remediation_ro en lecture pour la remédiation	docker-compose.yml, infra/postgres	Fait
Accès Docker par proxys : lecture seule (supervision), redémarrage seul (remédiation)	docker-compose.yml	Fait
Alertes du détecteur authentifiées par jeton (comparaison à temps constant), alertes rejouées ignorées	infra/remediation-engine/engine.py	Fait
Garde-fous du moteur : 90 s entre deux actions par service, 3 actions max en 10 min, playbooks en liste blanche	engine.py, ansible/group_vars/all.yml	Fait
Conteneurs durcis : no-new-privileges, read_only et cap_drop sur la plupart, limites CPU/RAM sur certains	docker-compose.yml	Partiel
Secrets : .env.enc / secrets.enc.env chiffrés SOPS + age, déchiffrés en .env ; passés en variables d'environnement	scripts/decrypt_secrets.sh	Partiel

7 Écarts avec l'architecture cible validée (v2.1)

Point	Cible v2.1 (19/10)	Construit (21/10)	Commentaire
Nombre de services	13 conteneurs	17 services	Ajout de traffic-gen, cadvisor, docker-stats-exporter, 2 proxys Docker ; ml-detector séparé
Réseaux	2 (front, back)	5 zones (edge, app, data, monitoring, remediation)	Plus fin que prévu : meilleure isolation
WAF	Nginx + ModSecurity (OWASP CRS), port 80	nginx : liste blanche + liste de blocage, port 8082	Double WAF : nginx (liste blanche, blocage) + WAF applicatif dans payment-api (waf.py) ; pas de règles OWASP
Détection + remédiation	Un service resilience-engine qui lit Prometheus	ml-detector + remediation (séparés), le détecteur lit Loki	Boucle en place depuis le 20/10 au soir ; séparation plus sûre (le détecteur ne touche pas à Docker)
Assistant IA	Conteneurs assistant + ollama	ai-api (ML + RAG) + Ollama hors Docker	Ollama sur le PC IA (.60) : PC IA utilisé, contrairement à la cible
Authentification	auth, JWT RS256 (clé privée isolée)	auth, JWT HS256 (secret partagé)	payment-api détient aussi le secret de signature
Secrets	SOPS → fichiers /run/secrets	SOPS → .env → variables d'environnement	Visibles avec docker inspect
Grafana	127.0.0.1 uniquement	Publié sur le Wi-Fi (3000), avec compte	Choix de l'équipe, risque documenté
Dashboard	/dashboard local, bloqué par le WAF	Dans le front, accessible via le WAF	Visible par tout le Wi-Fi, y compris l'attaquant

8 Points d'attention avant la démo

- **Mesurer la boucle de bout en bout sur le PC Hôte** : attaque depuis le PC Attaquant → détection (au plus tôt 2 cycles de 5 s) → playbook → paiement de test. C'est le chiffre attendu par le jury (axe 1).
- **Le modèle juge l'anomalie, des règles choisissent la réponse** : une alerte ne part que si une cause est reconnue (conteneur arrêté, majorité de refus 429/503, outil d'attaque ou 403). À expliquer clairement au jury.
- **La limitation posée par la remédiation s'applique à tous les clients extérieurs** (même IP vue par le WAF sous Docker Desktop) et n'est jamais retirée automatiquement : prévoir make unblock après la démo.
- **Bloquer une source redémarre le WAF** (quelques secondes de coupure pour tous).
- **Le service IA télécharge son modèle d'embeddings sur Internet au démarrage**, alors qu'il n'y aura pas d'Internet pendant la démo : à intégrer dans l'image.
- **Le RAG ne lit que procedures.pdf** : les documents de gouvernance (docs/gouvernance/*.md) ne sont pas encore chargés.
- **/api/waf/status est public** : il expose la liste des IP bannies et les statistiques du pare-feu.